


Statistiques descriptives

COURS DE MATHÉMATIQUES — FICHE N° 8



Objectifs pédagogiques de la fiche

À l'issue de ce cours, l'étudiant · e sera capable de :

- manier le **vocabulaire statistique** (population, caractère, effectif, modalité, classe, centre de classe) et distinguer caractère **qualitatif** / **quantitatif** (discret ou continu) ;
- construire un **tableau statistique complet** : effectifs n_i , effectif total N , fréquences f_i , effectifs et fréquences **cumulés** ;
- calculer et interpréter les **indicateurs de position** : **mode** M , **moyenne** m , **médiane** Me et **quartiles** Q_1, Q_3 ;
- déterminer une médiane par **interpolation linéaire** (méthode des triangles semblables) ou par lecture graphique de la **courbe des fréquences cumulées** ;
- calculer et interpréter les **indicateurs de dispersion** : **étendue**, **écart moyen** σ_m , **variance** V (formule directe et théorème de **König–Huygens**), **écart type** $\sigma = \sqrt{V}$;
- lire et tracer les représentations graphiques : **diagramme en bâtons**, **histogramme**, **polygone des fréquences**, **polygone cumulé (ogive)** ;
- commenter, *en français*, la signification concrète de chaque résultat chiffré.

Table des matières

1	Introduction : à quoi sert la statistique descriptive ?	3
2	Le vocabulaire de base de la statistique	3
2.1	Population, individu, caractère, modalité	3
2.2	Les trois types de caractères	4
2.3	Classe, amplitude et centre de classe	4
3	La série statistique et le tableau d'effectifs	5
3.1	Effectif, effectif total et effectif cumulé	5
3.2	Fréquence et fréquence cumulée	6
3.3	Le tableau statistique complet	6
4	Les indicateurs de position (tendance centrale)	7
4.1	Le mode M	7
4.2	La moyenne arithmétique m	7
4.3	La médiane Me	9
4.3.1	Médiane d'une série discrète (valeurs listées)	9
4.3.2	Médiane d'une série regroupée en classes : l'interpolation linéaire	10
4.3.3	Lecture graphique de la médiane sur l'ogive	11
4.4	Les quartiles Q_1, Q_2, Q_3	11
5	Les indicateurs de dispersion	13
5.1	L'étendue	13
5.2	L'écart à la moyenne et l'écart moyen σ_m	13
5.3	La variance V	14
5.4	L'écart type σ	16
6	Représentations graphiques	16
6.1	Diagramme en bâtons (caractère discret)	17
6.2	Histogramme (caractère continu, regroupé en classes)	17
6.3	Polygone des fréquences et polygone cumulé (ogive)	18
6.4	Boîte à moustaches (récapitulative)	18
7	Méthodologie complète : étudier une série de A à Z	18
8	Synthèse : formulaire, méthodes et points-clés	20

1 Introduction : à quoi sert la statistique descriptive ?

Chaque jour, on est noyé sous des *nombres* : la taille des élèves d'une classe, les notes à un examen, la tension artérielle de 200 patients, le nombre de globules blancs par mm^3 de sang, le prix d'un médicament dans dix pharmacies. . . Pris individuellement, ces nombres ne disent pas grand-chose. La **statistique descriptive** est l'ensemble des outils qui permettent de **résumer** une grande masse de données par quelques chiffres parlants et par quelques graphiques.

Concrètement, décrire une série statistique, c'est répondre à trois familles de questions :

- **Quel est le « centre » de la série ?** autour de quelle valeur les données se regroupent-elles ?
→ indicateurs de **position** (*mode, moyenne, médiane*) ;
- **Les données sont-elles resserrées ou étalées ?** → indicateurs de **dispersion** (*étendue, écart moyen, variance, écart type*) ;
- **Comment visualiser tout cela d'un coup d'œil ?** → représentations **graphiques** (diagramme en bâtons, histogramme, courbe cumulée).

Remarque : l'objet de la fiche

Cette fiche ne traite que de la statistique **descriptive** (résumer des données que l'on possède). Elle ne fait *pas* de statistique **inférentielle** (tirer des conclusions sur une population entière à partir d'un échantillon, tests, probabilités). On reste du côté *descriptif* : tout ce que l'on calcule, on le calcule sur les données elles-mêmes.

2 Le vocabulaire de base de la statistique

Avant tout calcul, il faut fixer le vocabulaire : un mot = une idée précise. Toute la fiche réutilisera ces termes.

2.1 Population, individu, caractère, modalité

Définition 2.1 — population et individu

La **population** est l'*ensemble* de tous les éléments sur lesquels porte l'étude statistique. Chaque élément de cet ensemble est un **individu** (ou *unité statistique*). Le **nombre d'individus** de la population est l'**effectif total**, noté N .

Définition 2.2 — caractère et modalité

Le **caractère** (ou *variable*) est la *propriété* que l'on étudie sur chaque individu. Les **valeurs** que peut prendre ce caractère sont les **modalités**, en général notées x_i (l'indice i numérote les modalités : $i = 1, 2, \dots, k$).

Exemple : fil rouge de la fiche

On étudie la **taille** (en millimètres) de $N = 65$ poissons élevés dans un aquarium.

- **Population** : les 65 poissons de l'aquarium.
- **Individu** : un poisson.
- **Caractère** : la taille (en mm).
- **Effectif total** : $N = 65$.

Cet exemple nous accompagnera du début à la fin : on y calculera *tous* les indicateurs.

2.2 Les trois types de caractères

Définition 2.3 — types de caractère

- Un caractère est **qualitatif** si ses modalités ne sont pas des nombres (groupe sanguin, couleur des yeux, sexe).
- Un caractère est **quantitatif** si ses modalités sont des nombres. On distingue :
 - **discret** : il prend des valeurs *isolées* (le nombre d'enfants par famille : 0, 1, 2, ...);
 - **continu** : il peut prendre *toute* valeur d'un intervalle (taille, masse, température). On le découpe alors en **classes** $[a, b[$.

Attention : caractère continu $\Rightarrow$ classes

Dès qu'un caractère est continu (ou qu'il prend beaucoup de valeurs différentes), on **regroupe** les données en **classes** de la forme $[a, b[$, par tranches de même *amplitude*. Chaque classe est ensuite représentée par un seul nombre, son **centre**.

2.3 Classe, amplitude et centre de classe

Définition 2.4 — classe et centre de classe

Une **classe** est un intervalle $[a, b[$ qui regroupe les valeurs d'un caractère continu.

- Son **amplitude** (ou largeur) vaut $b - a$.
- Son **centre** (ou *valeur centrale*) est le milieu de l'intervalle :

Formule 2.1 — centre de classe

$$x_i = \frac{a + b}{2}$$

où :

- a : borne *inférieure* de la classe (comprise);
- b : borne *supérieure* de la classe (exclue);
- x_i : centre de la classe — c'est lui que l'on utilisera dans *tous* les calculs.

Unité : celle du caractère (ici des mm). Le centre n'a *pas* de dimension propre : il hérite de celle du caractère.

Exemple : centres des classes du fichier « poissons »

Les tailles sont découpées en classes d'amplitude 10 mm : $[55, 65[$, $[65, 75[$, etc. Le centre de la première classe est $x_1 = \frac{55 + 65}{2} = 60$ mm, celui de la quatrième est $x_4 = \frac{85 + 95}{2} = 90$ mm, et ainsi de suite (voir le tableau de la section 3).

Remarque : caractère discret $\Rightarrow$ pas de classe

Pour un caractère **discret**, il n'y a *pas* de colonne « classes » : la colonne des centres est remplacée directement par les valeurs entières x_i . **Toutes les formules restent strictement les mêmes**, on remplace simplement « centre de classe » par « valeur de la modalité ».

3 La série statistique et le tableau d'effectifs

Le point de départ obligatoire de tout calcul est un **tableau statistique** propre et complet. C'est lui qui contient les données « brutes » transformées en colonnes exploitables.

3.1 Effectif, effectif total et effectif cumulé

Définition 3.1 — effectif

L'**effectif** n_i d'une modalité (ou d'une classe) est le **nombre d'individus** qui présentent cette valeur du caractère. C'est un entier naturel.

Formule 3.1 — effectif total

$$N = \sum_{i=1}^k n_i = n_1 + n_2 + \cdots + n_k$$

où :

- n_i : effectif de la i^{e} classe ;
- k : nombre total de classes (ou de modalités) ;
- N : effectif total de la population (somme de toutes les lignes).

Unité : ce sont des **effectifs** (des *comptes* d'individus), donc sans unité physique. Vérification indispensable : la somme de la colonne n_i *doit* redonner N .

Définition 3.2 — effectif cumulé n_c

L'**effectif cumulé** n_c d'une classe est le nombre d'individus dont la valeur du caractère est *inférieure ou égale* à la borne supérieure de cette classe. Il s'obtient en additionnant les effectifs de toutes les classes *précédentes*, y compris celle-ci.

Exemple : effectifs cumulés des poissons

Pour la série de 66 poissons (variante), la colonne n_c se construit de proche en proche :

Classes (mm)	x_i	n_i	n_c
[55,65[	60	4	4
[65,75[	70	2	$4 + 2 = 6$
[75,85[	80	6	$6 + 6 = 12$
[85,95[	90	18	$12 + 18 = \mathbf{30}$
[95,105[	100	14	$30 + 14 = \mathbf{44}$

Lecture : 30 poissons mesurent moins de 95 mm ; 44 poissons mesurent moins de 105 mm. On verra que ces cumuls servent à localiser la **médiane** et les **quartiles**.

3.2 Fréquence et fréquence cumulée

Définition 3.3 — fréquence

La **fréquence** f_i de la i^{e} classe est la *proportion* d'individus qui appartiennent à cette classe. C'est un nombre compris entre 0 et 1 ; multiplié par 100, elle donne le **pourcentage**.

Formule 3.2 — fréquence et fréquence cumulée

$$\boxed{f_i = \frac{n_i}{N}} \quad \text{et} \quad f_c = \sum_{j=1}^i f_j = f_1 + f_2 + \cdots + f_i$$

où :

- n_i : effectif de la classe ;
- N : effectif total ;
- f_i : fréquence de la classe (en décimal) ; $f_i \times 100 = \text{pourcentage}$;
- f_c : fréquence *cumulée* jusqu'à la classe i (la dernière vaut toujours $1 = 100\%$).

Unité : aucune, f_i est un nombre sans dimension (souvent écrit en $\%$). Propriété de contrôle :

$$\sum_{i=1}^k f_i = 1.$$

Exemple : calcul d'une fréquence

Sur la série de $N = 65$ poissons, la classe $[65,75[$ contient $n_2 = 2$ poissons. Sa fréquence vaut $f_2 = \frac{n_2}{N} = \frac{2}{65} = 0,03$, c'est-à-dire 3% des poissons. La fréquence cumulée après les quatre premières classes vaut $f_c = f_1 + f_2 + f_3 + f_4 = 0,06 + 0,03 + 0,09 + 0,28 = 0,46$: 46% des poissons mesurent moins de 95 mm.

3.3 Le tableau statistique complet

Comment faire : construire un tableau statistique complet

1. Lister les **classes** $[a,b[$ (ou les valeurs x_i si discret) en ligne, $i = 1 \dots k$.
2. Compter l'**effectif** n_i de chaque classe, puis vérifier $N = \sum n_i$.
3. Calculer chaque **centre de classe** $x_i = (a + b)/2$.
4. Calculer chaque **fréquence** $f_i = n_i/N$ (arrondir à 0,01).
5. Construire la colonne **fréquence cumulée** f_c en sommant de proche en proche ; la dernière ligne doit valoir 1,00.

Voici le tableau complet de notre exemple fil rouge (65 poissons), tel qu'il servira de base à tous les calculs de la fiche :

Ligne i	Classes (mm)	Centre x_i	Effectif n_i	Fréq. f_i	Fréq. cum. f_c
1	[55,65[	60	4	0,06	0,06
2	[65,75[	70	2	0,03	0,09
3	[75,85[	80	6	0,09	0,18
4	[85,95[	90	18	0,28	0,46
5	[95,105[	100	14	0,22	0,68
6	[105,115[	110	10	0,15	0,83
7	[115,125[	120	6	0,09	0,92
8	[125,135[	130	5	0,08	1,00
Totaux		—	$N = 65$	1,00	

4 Les indicateurs de position (tendance centrale)

Les indicateurs de position résument la série par une valeur « typique » autour de laquelle les données se répartissent. Il en existe trois, complémentaires : le **mode**, la **moyenne** et la **médiane**.

4.1 Le mode M

Définition 4.1 — *mode*

Le **mode** M est la **modalité** (ou la **classe**, ou la *valeur du caractère*) dont l'**effectif est le plus grand**. C'est la valeur « la plus fréquente », celle qui apparaît le plus souvent. Le mode n'est *pas* forcément unique.

Exemple : *mode du fichier poissons*

La classe [85,95[(ligne 4) a l'effectif maximal $n_4 = 18$. C'est donc le mode : $M = [85,95[$ (ou $M = 90$ mm si l'on parle du centre de la classe modale). En d'autres termes, la taille *la plus représentée* chez ces 65 poissons se situe entre 85 et 95 mm.

Attention : *mode d'une série discrète*

Pour un caractère discret, le mode est une *valeur*, pas une classe. Par exemple, dans la série « note/10 : 2 (15 élèves), 5 (10 élèves), 8 (5 élèves) », le plus grand effectif est 15, donc le mode est $M = 2$.

4.2 La moyenne arithmétique m

La moyenne est l'indicateur de position le plus utilisé. Attention : avec des classes, ce n'est *pas* une moyenne simple, car chaque valeur x_i représente plusieurs individus : c'est une **moyenne pondérée** (pondérée par les effectifs n_i).

Formule 4.1 — *moyenne arithmétique d'une série regroupée*

$$m = \frac{1}{N} \sum_{i=1}^k n_i x_i = \frac{n_1 x_1 + n_2 x_2 + \cdots + n_k x_k}{N}$$

où :

— x_i : centre de la i^{e} classe (ou valeur de la modalité si discret) ;

- n_i : effectif de cette classe (le « poids » de la valeur x_i) ;
- $N = \sum n_i$: effectif total ;
- m : moyenne arithmétique de la série.

Unité : la même que le caractère (ici des **mm**). La moyenne se calcule *toujours* avec les centres de classe, jamais avec les bornes.

Propriété 4.1 — la moyenne est linéaire

Si l'on **ajoute** une constante a à toutes les valeurs d'une série, la moyenne augmente de a . Si l'on **multiplie** toutes les valeurs par un facteur λ , la moyenne est multipliée par λ . Formellement : $\overline{x+a} = m+a$ et $\overline{\lambda x} = \lambda m$.

Exemple : calcul complet de la moyenne — poissons, 65 individus

On applique la formule avec les centres et les effectifs du tableau de la section 3 :

$$m = \frac{4 \times 60 + 2 \times 70 + 6 \times 80 + 18 \times 90 + 14 \times 100 + 10 \times 110 + 6 \times 120 + 5 \times 130}{65}.$$

Numérateur (somme des produits $n_i x_i$) :

$$4 \times 60 = 240, 2 \times 70 = 140, 6 \times 80 = 480, 18 \times 90 = 1620, \\ 14 \times 100 = 1400, 10 \times 110 = 1100, 6 \times 120 = 720, 5 \times 130 = 650,$$

soit un total de $240 + 140 + 480 + 1620 + 1400 + 1100 + 720 + 650 = \mathbf{6350}$.

$$m = \frac{6350}{65} = \mathbf{97,69 \text{ mm.}}$$

Interprétation : « En moyenne, un poisson de cet aquarium mesure 97,69 mm. »

Exemple : moyenne d'une petite série discrète

Notes sur 10 d'un groupe d'élèves : la note 2 est obtenue par 15 élèves, la note 5 par 10 élèves, la note 8 par 5 élèves. Effectif total $N = 15 + 10 + 5 = 30$.

$$m = \frac{2 \times 15 + 5 \times 10 + 8 \times 5}{30} = \frac{30 + 50 + 40}{30} = \frac{120}{30} = \mathbf{4,00/10}.$$

On retrouve bien la moyenne *pondérée* : la note 2, très fréquente (15 élèves), tire la moyenne vers le bas.

Comment faire : manipuler la moyenne par changement d'échelle

Problème : comment modifier une série pour atteindre une moyenne cible? *Procédé* (très utile au concours) : grâce à la linéarité de la moyenne, il suffit de tester l'effet d'une translation $\lambda \mapsto \lambda x + c$.

- On part de la série x_i de moyenne connue m .
- La nouvelle moyenne après $x_i \mapsto \alpha x_i + \beta$ vaut $\alpha m + \beta$.
- On résout $\alpha m + \beta = m_{\text{cible}}$ pour trouver le bon α, β .

Application. Avec la série précédente ($m = 4$), on veut atteindre une moyenne de 5,00/10. Si l'on ajoute 1 point à chaque note ($x_i \mapsto x_i + 1$, donc $\alpha = 1, \beta = 1$), la nouvelle moyenne vaut $4 + 1 = 5$. **C'est donc « ajouter 1 point à chaque valeur » qui convient.** (Vérification :

$$\frac{3 \times 15 + 6 \times 10 + 9 \times 5}{30} = \frac{45 + 60 + 45}{30} = \frac{150}{30} = 5.)$$

4.3 La médiane Me

Définition 4.2 — médiane

La **médiane** Me est la valeur du caractère qui **partage l'effectif en deux groupes de même taille** : environ la moitié des individus ont une valeur *inférieure ou égale* à Me , l'autre moitié une valeur *supérieure ou égale*. C'est la valeur qui correspond à une **fréquence cumulée de 50 %**.

La médiane se détermine différemment selon que la série est **discrète** (valeurs rangées une à une) ou **regroupée en classes**.

4.3.1 Médiane d'une série discrète (valeurs listées)

Formule 4.2 — médiane d'une série de n valeurs rangées par ordre croissant

- Si n est **impair** : la médiane est la valeur située au rang $\frac{n+1}{2}$.
- Si n est **pair** : la médiane est la **moyenne arithmétique** des valeurs situées aux rangs $\frac{n}{2}$ et $\frac{n}{2} + 1$.

Exemple : médiane, n impair

Série : 1; 4; 2; 16; 8; 10; 5; 20; 3 ($n = 9$ valeurs).

1^{re} étape, *indispensable* : on **range par ordre croissant** :

1; 2; 3; 4; $\underbrace{5}_{\text{rang 5}}$; 8; 10; 16; 20.

2^e étape : $n = 9$ est impair, donc la médiane est la valeur de rang $\frac{n+1}{2} = \frac{10}{2} = 5$, soit la valeur **5**.

Interprétation : 4 valeurs sont ≤ 5 et 4 valeurs sont ≥ 5 .

Exemple : médiane, n pair

Série : 1; 4; 2; 17; 7; 10; 5; 20; 3; 6 ($n = 10$ valeurs).

On range par ordre croissant :

1; 2; 3; 4; $\underbrace{5}_{\text{rang 5}}$; $\underbrace{6}_{\text{rang 6}}$; 7; 10; 17; 20.

$n = 10$ est pair : la médiane est la moyenne des valeurs de rang $\frac{n}{2} = 5$ et $\frac{n}{2} + 1 = 6$, c'est-à-dire $Me = \frac{5+6}{2} = \mathbf{5,5}$.

Attention : la première étape est toujours le tri

Tant que la série n'est pas rangée par ordre croissant, la notion de médiane n'a *aucun* sens. C'est l'erreur n° 1 : oublier de trier.

4.3.2 Médiane d'une série regroupée en classes : l'interpolation linéaire

Lorsque les données sont groupées en classes, on ne connaît plus les valeurs individuelles : on sait seulement *combien* d'individus tombent dans chaque classe. La médiane se calcule alors par **interpolation linéaire** à l'intérieur de la « classe médiane » — celle qui contient le $\left(\frac{N}{2}\right)^e$ individu. La méthode repose sur la *similitude des triangles* (on suppose les individus répartis *uniformément* dans la classe médiane).

Formule 4.3 — médiane par interpolation linéaire (méthode des triangles semblables)

$$\frac{Me - a}{r} = \frac{b - a}{n_{\text{classe}}} \implies Me = a + \frac{r}{n_{\text{classe}}} (b - a)$$

où :

- $[a, b]$: la **classe médiane**, c'est-à-dire la classe qui contient le $\left(\frac{N}{2}\right)^e$ individu (repérée grâce aux effectifs cumulés) ;
- a : borne inférieure de cette classe ;
- b : borne supérieure de cette classe ;
- n_{classe} : effectif total de la classe médiane (largeur « verticale ») ;
- r : **rang** du $\left(\frac{N}{2}\right)^e$ individu à l'intérieur de la classe médiane, soit $r = \frac{N}{2} - n_c^{\text{préc}}$ où $n_c^{\text{préc}}$ est l'effectif cumulé de la classe *précédente* ;
- Me : médiane cherchée.

Unité : celle du caractère (mm). Le rapport $\frac{r}{n_{\text{classe}}} \in [0, 1]$ est la *proportion* du chemin parcouru dans la classe.

Comment faire : calculer une médiane par interpolation linéaire en 4 étapes

1. **Calculer** le rang visé : $\frac{N}{2}$ (la moitié de l'effectif total).
2. **Localiser la classe médiane** à l'aide des effectifs cumulés n_c : c'est la première classe dont l'effectif cumulé *dépasse* (ou atteint) $\frac{N}{2}$.
3. **Calculer le rang intérieur** $r = \frac{N}{2} - n_c^{\text{préc}}$ (ce qui « reste » à parcourir dans la classe médiane).
4. **Appliquer** $Me = a + \frac{r}{n_{\text{classe}}} (b - a)$.

Exemple : médiane par interpolation — série de 66 poissons

Voici la série (**attention**, $N = 66$ ici, légèrement différente de l'exemple 65) :

Classes (mm)	x_i	n_i	n_c
[55,65[	60	4	4
[65,75[	70	2	6
[75,85[	80	6	12
[85,95[	90	18	30
[95,105[	100	14	44
[105,115[	110	10	54
[115,125[	120	6	60
[125,135[	130	6	66

Étape 1. Le rang visé est $\frac{N}{2} = \frac{66}{2} = \mathbf{33}$. On cherche donc le 33^e poisson (rangé du plus petit au plus grand).

Étape 2. Dans les effectifs cumulés, on cherche la première classe dont le cumul atteint ou dépasse 33 : la classe [85,95[s'arrête à 30 (trop tôt), la classe [95,105[monte à 44 (assez). La **classe médiane** est donc [95,105[, soit $a = 95$, $b = 105$.

Étape 3. Le 33^e poisson occupe, à l'intérieur de la classe médiane, le rang $r = 33 - 30 = \mathbf{3}$ (il est le 3^e poisson de la classe). L'effectif de la classe médiane est $n_{\text{classe}} = 14$.


Étape 4. Interpolation :

$$\frac{Me - 95}{3} = \frac{105 - 95}{14} = \frac{10}{14} \implies Me = 95 + 3 \times \frac{10}{14} = 95 + \frac{30}{14} = 95 + 2,14 = \mathbf{97,14 \text{ mm.}}$$

Interprétation : « 50 % des poissons mesurent moins de 97,14 mm, et 50 % mesurent plus de 97,14 mm. »

4.3.3 Lecture graphique de la médiane sur l'ogive

La médiane peut aussi se lire **directement** sur le **polygone des fréquences cumulées** (ou *ogive*) : on cherche la valeur du caractère qui correspond à une fréquence cumulée de 50 %. Graphiquement, on part de $f_c = 0,50$ sur l'axe vertical, on rejoint la courbe, puis on redescend sur l'axe horizontal : on lit la médiane. C'est exactement la même information que le calcul par interpolation.



Remarque : moyenne $\neq$ médiane

La moyenne (97,69) et la médiane (97,14) sont *proches* mais *distinctes* : la moyenne est sensible aux valeurs extrêmes, la médiane ne l'est pas. Quand une série est **dissymétrique** (quelques très grandes valeurs, par exemple), la moyenne est tirée vers ces valeurs alors que la médiane reste stable : il faut alors regarder les deux.

4.4 Les quartiles Q_1 , Q_2 , Q_3

La médiane coupe la série en *deux* ; les **quartiles** la coupent en *quatre* parts égales. Ils affinent la description de la répartition.

Définition 4.3 — *quartiles*

Les **quartiles** sont les trois valeurs qui partagent la série (rangée par ordre croissant) en **quatre groupes d'effectifs égaux** :

- Q_1 : **premier quartile** — la plus petite valeur pour laquelle au moins 25 % des données lui sont inférieures ou égales ;
- Q_2 : **deuxième quartile** = la **médiane** Me (50 %) ;
- Q_3 : **troisième quartile** — la plus petite valeur pour laquelle au moins 75 % des données lui sont inférieures ou égales.

Formule 4.4 — *quartiles par interpolation linéaire*

On applique la *même* méthode que pour la médiane, mais en visant le rang $\frac{N}{4}$ (pour Q_1) ou $\frac{3N}{4}$ (pour Q_3) au lieu de $\frac{N}{2}$:

$$Q_1 = a + \frac{r_1}{n_{\text{classe}}}(b - a), \quad Q_3 = a + \frac{r_3}{n_{\text{classe}}}(b - a),$$

où $[a, b[$ est la classe contenant le $\left(\frac{N}{4}\right)^e$ (resp. $\left(\frac{3N}{4}\right)^e$) individu, et r_1 (resp. r_3) est son rang intérieur.

Exemple : calcul de Q_1 — test noté sur 20, $N = 40$ élèves

Classes (/20)	x_i	n_i	n_c
$[0,4[$	2	4	4
$[4,8[$	6	8	12
$[8,12[$	10	10	22
$[12,16[$	14	12	34
$[16,20[$	18	6	40

Étape 1. Rang visé pour Q_1 : $\frac{N}{4} = \frac{40}{4} = 10$.

Étape 2. La première classe s'arrête à 4 (trop tôt), la deuxième monte à 12 : la classe de Q_1 est $[4,8[$, donc $a = 4$, $b = 8$, $n_{\text{classe}} = 8$.

Étape 3. Rang intérieur $r_1 = 10 - 4 = 6$.

Étape 4.

$$Q_1 = 4 + \frac{6}{8}(8 - 4) = 4 + \frac{6}{8} \times 4 = 4 + 3 = \mathbf{7/20}.$$

Interprétation : « 25 % des élèves ont eu moins de 7/20, 75 % ont eu plus. »

Propriété 4.2 — *les quartiles encadrent la dispersion centrale*

L'**écart interquartile** $Q_3 - Q_1$ mesure la dispersion des 50 % « centraux » des données : plus il est petit, plus les données du milieu sont resserrées. Contrairement à l'étendue, il est *peu sensible* aux valeurs extrêmes.

5 Les indicateurs de dispersion

Deux séries peuvent avoir la *même moyenne* mais des dispersions *très différentes* (pensez à $[10; 10; 10]$ et $[0; 10; 20]$: moyenne 10 dans les deux cas !). Les indicateurs de dispersion mesurent donc **l'étalement** des données autour du centre.

5.1 L'étendue

Définition 5.1 — étendue

L'**étendue** d'une série est la différence entre la plus grande et la plus petite valeur du caractère :

$$\text{étendue} = x_{\max} - x_{\min}.$$

C'est l'indicateur de dispersion le plus *simple* mais aussi le plus *grossier* (il ne tient compte que des deux extrêmes).

Exemple : étendue des poissons

La plus petite classe commence à 55 mm, la plus grande finit à 135 mm : l'étendue vaut $135 - 55 = 80$ mm. Les tailles s'étalent sur 80 mm.

5.2 L'écart à la moyenne et l'écart moyen σ_m

Définition 5.2 — écart à la moyenne

Pour chaque classe, l'**écart à la moyenne** est la **valeur absolue** de l'écart entre le centre de classe et la moyenne :

$$|m - x_i|.$$

C'est la « distance » (positive) entre la valeur x_i et la moyenne m .

Formule 5.1 — écart moyen σ_m

$$\sigma_m = \frac{1}{N} \sum_{i=1}^k n_i |m - x_i| = \frac{n_1|m - x_1| + n_2|m - x_2| + \cdots + n_k|m - x_k|}{N}$$

où :

- x_i : centre de la classe ;
- m : moyenne de la série ;
- n_i : effectif de la classe ;
- N : effectif total ;
- σ_m : écart moyen (moyenne des écarts, pondérée par les effectifs).

Unité : la même que le caractère (mm). On utilise la **valeur absolue** car la somme « naïve » des écarts ($m - x_i$), pondérée, vaut toujours 0 (les écarts positifs et négatifs se compensent exactement) : il faut donc prendre leurs valeurs absolues pour qu'ils ne s'annulent pas.

Exemple : calcul de l'écart moyen — poissons, $m = 97,69$

On dresse la colonne $|m - x_i|$ puis $n_i |m - x_i|$:

x_i	n_i	$ m - x_i $	$n_i m - x_i $
60	4	37,69	150,76
70	2	27,69	55,38
80	6	17,69	106,14
90	18	7,69	138,42
100	14	2,31	32,34
110	10	12,31	123,10
120	6	22,31	133,86
130	5	32,31	161,55
$N = 65$		Total	901,55

$$\sigma_m = \frac{901,55}{65} = \mathbf{13,87 \text{ mm.}}$$

Interprétation : « En moyenne, la taille d'un poisson s'écarte, de part et d'autre de la moyenne (97,69 mm), de 13,87 mm. »

5.3 La variance V

L'écart moyen utilise la valeur absolue, peu pratique algébriquement (non dérivable en 0). Pour avoir une mesure de dispersion *meilleure*, on élève les écarts **au carré** avant de les moyenner : c'est la **variance**.

Formule 5.2 — variance V (formule directe, « moyenne des carrés des écarts »)

$$V = \frac{1}{N} \sum_{i=1}^k n_i (m - x_i)^2$$

où :

- x_i : centre de classe ; m : moyenne ; n_i : effectif ; N : effectif total ;
- V : variance.

Unité : le **carré** de l'unité du caractère (ici des mm²). Comme V est une somme de termes *positifs*, on a toujours $V \geq 0$, et $V = 0$ *ssi* toutes les valeurs sont égales à la moyenne (aucune dispersion).

Exemple : calcul de la variance — poissons

On élève la colonne $|m - x_i|$ au carré :

x_i	n_i	$(m - x_i)^2$	$n_i(m - x_i)^2$
60	4	1420,54	5682,14
70	2	766,74	1533,47
80	6	312,94	1877,62
90	18	59,14	1064,45
100	14	5,34	74,71
110	10	151,54	1515,36
120	6	497,74	2986,42
130	5	1043,94	5219,68
$N = 65$		Total	19 953,85

$$V = \frac{19\,953,85}{65} = \mathbf{306,98 \text{ mm}^2}.$$

Propriété 5.1 — théorème de König–Huygens : formule de calcul de la variance

La variance peut aussi se calculer *sans* soustraire la moyenne à chaque ligne, ce qui évite les arrondis intermédiaires :

$$V = \frac{1}{N} \sum_{i=1}^k n_i x_i^2 - m^2 = \left(\frac{n_1 x_1^2 + \cdots + n_k x_k^2}{N} \right) - m^2$$

Autrement dit : la variance est égale à la moyenne des carrés, moins le carré de la moyenne.

où :

- $\sum n_i x_i^2$: somme des « carrés pondérés » (une seule colonne à calculer) ;
- m : moyenne de la série ;
- V : variance (même résultat qu’avec la formule directe, souvent *plus précis*).

Remarque : pourquoi König–Huygens est plus précis

La formule directe demande de calculer chaque $(m - x_i)$ puis de l’élever au carré : si m a été arrondi, l’erreur se propage dans *chaque* ligne. La formule de König–Huygens ne fait intervenir m qu’une seule fois (à la fin, via m^2) : elle est donc numériquement plus fiable. Les deux formules donnent rigoureusement le *même* résultat si l’on garde tous les chiffres.

Exemple : König–Huygens sur les poissons — vérification

On calcule la colonne $n_i x_i^2$:

x_i	n_i	x_i^2	$n_i x_i^2$
60	4	3600	14 400
70	2	4900	9800
80	6	6400	38 400
90	18	8100	145 800
100	14	10 000	140 000
110	10	12 100	121 000
120	6	14 400	86 400
130	5	16 900	84 500
$N = 65$		Total	640 300

$$V = \frac{640\,300}{65} - \left(\frac{6350}{65}\right)^2 = 9850,77 - 9543,79 = \mathbf{306,98 \text{ mm}^2}.$$

On retrouve *exactement* le même résultat : 306,98 mm².

5.4 L'écart type σ

La variance s'exprime dans une unité « au carré » (mm²), peu intuitive. On revient à l'unité d'origine en prenant la **racine carrée** de la variance : c'est l'**écart type**.

Formule 5.3 — écart type σ

$$\sigma = \sqrt{V}$$

où :

- V : variance de la série ;
- σ : écart type.

Unité : la *même* que le caractère (mm), puisque $\sqrt{\text{mm}^2} = \text{mm}$. L'écart type est l'indicateur de dispersion le plus utilisé car il s'exprime dans la bonne unité et se prête aux calculs (la variance, elle, s'additionne).

Exemple : écart type des poissons

$$\sigma = \sqrt{V} = \sqrt{306,98} = \mathbf{17,5 \text{ mm}}.$$

Interprétation : « La taille d'un poisson s'écarte, de part et d'autre de la moyenne (97,69 mm), d'environ 17,5 mm. » Remarquer que $\sigma = 17,5 > \sigma_m = 13,87$: c'est *normal*, car la variance *surpondère* les grands écarts (effet du carré).

Attention : comparer σ_m et σ


L'écart type est *toujours* supérieur ou égal à l'écart moyen ($\sigma \geq \sigma_m$) : c'est une conséquence de l'inégalité entre la moyenne quadratique et la moyenne arithmétique. Ne pas s'en étonner, ni confondre les deux indicateurs.

6 Représentations graphiques

Un graphique parle souvent plus qu'un tableau de nombres. Le choix du graphique dépend du type de caractère.

6.1 Diagramme en bâtons (caractère discret)

Pour un caractère **discret**, on représente chaque modalité x_i par un **bâton** dont la hauteur est proportionnelle à l'effectif n_i (ou à la fréquence f_i). Les bâtons sont *séparés* (il n'y a pas de valeurs entre deux modalités entières).




Exemple : lecture du diagramme

Le diagramme ci-dessus représente la série « notes/10 » (2 : 15 élèves, 5 : 10 élèves, 8 : 5 élèves). Le plus haut bâton ($x = 2$) désigne immédiatement le **mode** ($M = 2$).

6.2 Histogramme (caractère continu, regroupé en classes)

Pour un caractère **continu**, les classes étant contiguës, on colle les barres : on obtient un **histogramme**. Chaque classe est une barre de largeur $b - a$; la hauteur est proportionnelle à l'effectif n_i (ici toutes les classes ont la même amplitude, donc la hauteur $\propto n_i$).




Exemple : lecture de l'histogramme

La barre la plus haute (rouge) est la classe $[85,95[$: on lit directement le **mode**. La distribution est *dissymétrique* (étalée vers les grandes tailles) : la moyenne (97,69) est donc *légèrement supérieure* à la médiane (97,14), ce que l'on avait constaté par le calcul.

6.3 Polygone des fréquences et polygone cumulé (ogive)

En reliant les *sommets* des barres de l'histogramme (prises aux centres de classe), on obtient le **polygone des fréquences**. En reliant les points (b_i, f_c) — borne supérieure de chaque classe en abscisse, fréquence cumulée en ordonnée — on obtient le **polygone des fréquences cumulées**, ou **ogive**.




Comment faire : lire la médiane et les quartiles sur l'ogive

1. Repérer l'ordonnée 0,50 (50 %) sur l'axe vertical.
2. Suivre la ligne horizontale jusqu'à rencontrer l'ogive.
3. Redescendre verticalement vers l'axe horizontal : on lit la **médiane** Me .
4. Recommencer à 0,25 pour lire Q_1 , et à 0,75 pour lire Q_3 .

La précision est limitée par la lecture graphique (arrondie au mm près) : le calcul par interpolation linéaire est plus exact mais donne la *même* information.

6.4 Boîte à moustaches (récapitulative)

La **boîte à moustaches** (ou *box-plot*) résume en un seul dessin les cinq valeurs-clés d'une série : $x_{\min}$, Q_1 , Me , Q_3 , $x_{\max}$.



La largeur de la boîte ($Q_3 - Q_1$) est l'**écart interquartile** : elle montre d'un coup d'œil où se concentrent les 50 % centraux des données.

7 Méthodologie complète : étudier une série de A à Z

Pour fixer les idées, voici *l'enchaînement complet* des calculs sur un second exemple, traité de bout en bout.

Exemple : notes d'un test sur 20, $N = 40$ élèves — fiche

Un professeur répartit les notes (/20) de ses 40 élèves en cinq classes :

i	Classes (/20)	x_i	n_i	f_i	f_c
1	[0,4[	2	4	0,10	0,10
2	[4,8[	6	8	0,20	0,30
3	[8,12[	10	10	0,25	0,55
4	[12,16[	14	12	0,30	0,85
5	[16,20[	18	6	0,15	1,00

(a) **Effectif total et vérification.** $N = 4 + 8 + 10 + 12 + 6 = 40$ (et $\sum f_i = 1$: cohérent).

(b) **Mode.** Plus grand effectif $n_4 = 12$ sur la ligne 4, donc $M = [12,16[$ (ou $M = 14/20$).

(c) **Moyenne.**

$$m = \frac{4 \times 2 + 8 \times 6 + 10 \times 10 + 12 \times 14 + 6 \times 18}{40} = \frac{8 + 48 + 100 + 168 + 108}{40} \\ = \frac{432}{40} = 10,8/20.$$

(d) **Médiane** (rang $\frac{N}{2} = 20$). Effectifs cumulés : 4,12,22,... : le 20^e élève est dans la classe [8,12[, au rang intérieur $r = 20 - 12 = 8$:

$$Me = 8 + \frac{8}{10} (12 - 8) = 8 + \frac{8}{10} \times 4 = 8 + 3,2 = 11,2/20.$$

(e) **Premier quartile** Q_1 (rang $\frac{N}{4} = 10$). Le 10^e élève est dans [4,8[, au rang intérieur $r_1 = 10 - 4 = 6$:

$$Q_1 = 4 + \frac{6}{8} (8 - 4) = 4 + 3 = 7/20.$$

(f) **Variance** (par König-Huygens). On calcule $\sum n_i x_i^2$:

$$4(2)^2 + 8(6)^2 + 10(10)^2 + 12(14)^2 + 6(18)^2 = 16 + 288 + 1000 + 2352 + 1944 = 5600.$$

$$V = \frac{5600}{40} - (10,8)^2 = 140 - 116,64 = 23,36 \text{ (points/20)}^2.$$

(g) **Écart type.** $\sigma = \sqrt{23,36} = 4,83/20$.

Bilan commenté : la moyenne de la classe est 10,8/20 ; la moitié des élèves a eu une note comprise entre $Q_1 = 7$ et Q_3 , et les notes s'écartent de la moyenne d'environ 4,83 points. Notons que la médiane ($Me = 11,2$) est *légèrement supérieure* à la moyenne ($m = 10,8$) : cela traduit un léger étalement *vers les petites notes* (quelques très mauvaises copies tirent la moyenne vers le bas sans déplacer beaucoup la médiane).

Attention : règle de lecture : comparer m et Me

La position relative de la moyenne et de la médiane renseigne sur la **symétrie** de la distribution :

- si $m \approx Me$, la distribution est à peu près **symétrique** ;
- si $m > Me$, elle est **étalée vers le haut** (quelques très grandes valeurs tirent la moyenne vers le haut) ;
- si $m < Me$, elle est **étalée vers le bas** (quelques très petites valeurs tirent la moyenne vers le bas).

Toujours **comparer** m et Me : leur écart est un indicateur rapide de dissymétrie.

8 Synthèse : formulaire, méthodes et points-clés

Indicateur	Formule	À retenir
Effectif total	$N = \sum_{i=1}^k n_i$	somme de la colonne des effectifs
Fréquence	$f_i = \frac{n_i}{N}$	en décimal ($\times 100 = \%$); $\sum f_i = 1$
Centre de classe	$x_i = \frac{a+b}{2}$	utilisé dans tous les calculs
Mode M	classe d'effectif maximal	le plus fréquent ; valeur si discret
Moyenne m	$m = \frac{1}{N} \sum n_i x_i$	pondérée par les effectifs ; unité du caractère
Médiane Me	valeur à $f_c = 50\%$	partage l'effectif en deux
Médiane (classes)	$Me = a + \frac{r}{n_{\text{classe}}}(b-a)$	interpolation linéaire, $r = \frac{N}{2} - n_c^{\text{préc}}$
Quartile Q_1	$Q_1 = a + \frac{r_1}{n_{\text{classe}}}(b-a)$	rang visé $\frac{N}{4}$
Étendue	$x_{\max} - x_{\min}$	le plus simple, le plus grossier
Écart moyen σ_m	$\sigma_m = \frac{1}{N} \sum n_i m - x_i $	valeur absolue ; unité du caractère
Variance V	$V = \frac{1}{N} \sum n_i (m - x_i)^2$	unité au carré ; $V \geq 0$
König–Huygens	$V = \frac{1}{N} \sum n_i x_i^2 - m^2$	plus précis (une seule soustraction)
Écart type σ	$\sigma = \sqrt{V}$	même unité que le caractère ; $\sigma \geq \sigma_m$

Méthode : analyser une série statistique en six réflexes

1. **Construire** un tableau propre : classes $\rightarrow$ centres $x_i \rightarrow$ effectifs $n_i \rightarrow$ vérifier $N \rightarrow$ fréquences $f_i \rightarrow$ fréquences cumulées f_c .
2. **Position** : lire le mode, calculer la moyenne $m = \frac{1}{N} \sum n_i x_i$, déterminer la médiane (interpolation linéaire sur les classes, ou tri + formule de rang sur une série discrète).
3. **Dispersion** : étendue, puis variance (préférer König–Huygens) et écart type $\sigma = \sqrt{V}$.
4. **Vérifier la cohérence** : $\sum n_i = N$, $\sum f_i = 1$, $V \geq 0$, $\sigma \geq \sigma_m$, et comparer m et Me (symétrie).
5. **Conserver les unités** : m, Me, σ_m, σ dans l'unité du caractère ; V au carré ; f_i sans unité.
6. **Interpréter en français** : une moyenne ou un écart type sans phrase de conclusion ne vaut rien — dire *ce que le nombre signifie concrètement*.

L'essentiel de la Fiche 8

- **Vocabulaire** : *population* (N individus), *caractère* (qualitatif, ou quantitatif discret / continu $\rightarrow$ classes de centre $x_i = (a+b)/2$), *effectif* n_i , *fréquence* $f_i = n_i/N$.

- **Trois indicateurs de position** : le **mode** (valeur la plus fréquente), la **moyenne** $m = \frac{1}{N} \sum n_i x_i$ (pondérée), la **médiane** (valeur à 50 %). Sur des classes, la médiane se calcule par **interpolation linéaire** : $Me = a + \frac{r}{n_{\text{classe}}}(b - a)$.
- **Quartiles** Q_1, Q_3 : même méthode, rangs visés $\frac{N}{4}$ et $\frac{3N}{4}$; $Q_2 = Me$.
- **Dispersion** : **écart moyen** $\sigma_m = \frac{1}{N} \sum n_i |m - x_i|$, **variance** $V = \frac{1}{N} \sum n_i (m - x_i)^2$ (ou König-Huygens $V = \frac{1}{N} \sum n_i x_i^2 - m^2$), **écart type** $\sigma = \sqrt{V}$.
- **Unités** : m, Me, σ_m, σ ont l'unité du caractère ; V l'a au carré ; les fréquences sont sans unité.
- **Graphiques** : diagramme en bâtons (discret), histogramme (continu), ogive (cumulée) sur laquelle on lit Me, Q_1, Q_3 .
- **Toujours interpréter** un résultat par une phrase concrète en français.