


Statistiques descriptives

1 Synthèse



2 Indicateurs statistiques

Notations

x_i = la variable (discrète ou le centre de la classe), n_i = effectif, n_c = effectif cumulé, N = effectif total, f_i = fréquence, f_c = fréquence cumulée, M = mode (ou valeur dominante), m = moyenne arithmétique, Me = médiane, V = variance, σ_m = écart moyen et σ = écart type.

Définitions et formules d'application

Pour mieux maîtriser le calcul et la compréhension des indicateurs statistiques ci-dessus, nous présentons les résultats d'une étude statistique concernant la taille (en mm) de 65 poissons élevés dans un aquarium.

Ligne i	Classes (mm)	Valeur centrale x_i	Effectifs n_i	Fréquence f_i	Fréquence cumulée f_c
1	[55, 65[	60	4	0,06	0,06
2	[65, 75[	70	2	0,03	0,09
3	[75, 85[	80	6	0,09	0,18
4	[85, 95[	90	18	0,28	0,46
5	[95, 105[	100	14	0,22	0,68
6	[105, 115[	110	10	0,15	0,83
7	[115, 125[	120	6	0,09	0,92
8	[125, 135[	130	5	0,08	1,00


- x_i est le centre de la i -ème classe : par ex. en ligne 1, $x_{i=1} = \frac{55 + 65}{2} = 60$
- n_i est l'**effectif** de la i -ème classe : par ex. en ligne 3, $n_{i=3} = 6$
- N est l'**effectif total** : $N = \sum_{i=1}^{i=8} n_i = 4 + 2 + 6 + 18 + 14 + 10 + 6 + 5 = 65$
- $f_i = \frac{n_i}{N}$ est la **fréquence** de la i -ème classe, elle permet d'avoir le pourcentage correspondant à chacune des classes : par ex. en ligne 2, $f_{i=2} = \frac{2}{65} = 0,03$ (ou 3 %)
- f_c est la **fréquence cumulée**. Celle calculée en ligne 4 permet d'avoir le pourcentage correspondant aux quatre premières classes, soit $f_c = f_1 + f_2 + f_3 + f_4$.
- **M**, le **mode**, est la classe (ou la valeur du caractère ou la modalité) dont l'effectif est le plus grand. Dans le cas ci-dessus, il s'agit de la classe à la ligne 4, soit [85, 95[.

Dans le cas d'un caractère statistique discret, la colonne des classes disparaît et celle des valeurs centrales est remplacée par les nombres entiers x_i . Les formules pour les calculs restent les mêmes.

- m est la **moyenne arithmétique**, elle est égale à :

$$\begin{aligned}
 m &= \frac{1}{N} \sum_{i=1}^{i=8} n_i x_i \\
 &= \frac{4 \times 60 + 2 \times 70 + 6 \times 80 + 18 \times 90 + 14 \times 100 + 10 \times 110 + 6 \times 120 + 5 \times 130}{65} \\
 &= 97,69 \text{ (mm)}
 \end{aligned}$$

- Me , médiane, est la valeur du caractère (x_i) qui divise l'effectif en deux parties égales. Elle peut être déterminée :
 - Soit directement à partir du graphe des fréquences cumulées : la taille qui correspond à $f_c = 50\%$



- Soit par méthode « interpolation linéaire ».

Soit la série statistique ci-dessous concernant la taille (en mm) de 66 poissons dans un aquarium :

Classes (mm)	Valeur centrale x_i	Effectifs n_i	Effectifs cumulés n_c
[55, 65[	60	4	4
[65, 75[	70	2	6
[75, 85[	80	6	12
[85, 95[	90	18	30
[95, 105[	100	14	44
[105, 115[	110	10	54
[115, 125[	120	6	60
[125, 135[	130	6	66

La médiane correspond à la moyenne générale qui partage la série statistique en deux effectifs égaux, soit $66/2 = 33$. On peut dire aussi, qu'elle correspond à l'effectif cumulé 33.

Constatons donc que le 33^e poisson se trouve dans la classe [95, 105[et y occupe le 3^e rang ($33 - 30$).

Le calcul de la médiane décrit par la formule d'interpolation linéaire (ou similitude des triangles) est :

$$\frac{\text{Médiane} - \text{borne inférieure de la classe } [a, b[}{\text{rang du } \left(\frac{N}{2}\right)^{\text{e}} \text{ dans la classe } [a, b[}} = \frac{b - a}{\text{effectif de la classe } [a, b[}$$

La classe $[a, b[$ est la classe où se trouve le $\left(\frac{N}{2}\right)^{\text{e}}$ effectif.

Dans notre cas $[a, b[= [95, 105[$ et $\frac{N}{2} = \frac{66}{2} = 33$.

On obtient :

$$\begin{aligned} \text{Médiane} - \text{la borne inférieure de la classe } [95, 105[&= \frac{105 - 95}{14} \\ \text{rang du } \left(\frac{66}{2}\right)^e &\text{ dans la classe } [95, 105[\\ \Leftrightarrow \frac{\text{Médiane} - 95}{33 - 30} &= \frac{105 - 95}{14} \end{aligned}$$

$$\text{D'où : Médiane} = 3 \times \frac{10}{14} + 95 = 97,14 (\sim 97).$$

On en déduit donc que 50 % des poissons ont une taille inférieure ou égale à 97 mm et 50 % ont une taille supérieure ou égale à 97 mm.

- **Écart** : c'est la valeur absolue de la différence entre la valeur centrale et la moyenne.

Les valeurs des écarts sont calculées dans la colonne bleue :

Classes (mm)	Valeur centrale x_i	Effectifs n_i	Fréquence f_i	Fré. cumulée f_c	Écart $ m - x_i $	$ m - x_i \times n_i$
[55, 65[	60	4	0,06	0,06	37,69	150,76
[65, 75[	70	2	0,03	0,09	27,69	55,38
[75, 85[	80	6	0,09	0,18	17,69	106,14
[85, 95[	90	18	0,28	0,46	7,69	138,42
[95, 105[	100	14	0,22	0,68	2,31	32,34
[105, 115[	110	10	0,15	0,83	12,31	123,1
[115, 125[	120	6	0,09	0,92	22,31	133,86
[125, 135[	130	5	0,08	1,00	32,31	161,55
$N = 65$						
					Écart moyen	13,87

Si on calcule la moyenne de ces différents écarts, on obtient la valeur de l'**écart moyen** (σ_m) :

$$\begin{aligned} \sigma_m &= \frac{1}{N} \sum_{i=1}^{i=8} (|m - x_i| \times n_i) \\ &= \frac{4 \times 37,69 + 2 \times 27,69 + 6 \times 17,69 + 18 \times 7,69 + 14 \times 2,31 + 10 \times 12,31 + 6 \times 22,31 + 5 \times 32,31}{65} \\ &= 13,87 \end{aligned}$$

On conclut, EN MOYENNE, que la taille d'un poisson s'écarte de part et d'autre de la moyenne ($m = 97,69$) de 13,87 mm.

Pour avoir une meilleure mesure de dispersion, le carré des écarts est pris en compte dans les calculs. Pour cela, on calcule, la variance et l'écart type.

- **Variance V** : c'est une mesure caractérisant le degré de dispersion, est égale à la moyenne des carrés des écarts par rapport à la moyenne :

Classes (mm)	Valeur centrale x_i	Effectifs n_i	Fréquence f_i	Fré. cumulée f_c	$ m - x_i ^2$	$ m - x_i ^2 \times n_i$
[55, 65[	60	4	0,06	0,06	1 420,54	5 682,14
[65, 75[	70	2	0,03	0,09	766,74	1 533,47
[75, 85 [	80	6	0,09	0,18	312,94	1 877,62
[85, 95[	90	18	0,28	0,46	59,14	1 064,45
[95, 105[	100	14	0,22	0,68	5,34	74,71
[105, 115]	110	10	0,15	0,83	151,54	1 515,36
[115, 125[	120	6	0,09	0,92	497,74	2 986,42
[125, 135[	130	5	0,08	1,00	1 043,94	5 219,68
$N = 65$						19 953,85
					Variance	306,98

$$V = \frac{1}{N} \sum_{i=1}^{i=8} (|m - x_i|^2 \times n_i) = \frac{19\,953,85}{65} = 306,98$$

- **L'écart type (σ)** est égal à la racine carrée de la variance :

$$\sigma = \sqrt{V}$$

Soit, numériquement : $\sigma = 17,5$

On conclut donc que la taille d'un poisson s'écarte de part et d'autre de la moyenne ($m = 97,69$) de 17,5 mm.

Statistiques descriptives

1 Voici les notes sur vingt qu'un élève a eu en mathématiques :

$$\frac{10}{20} \quad \frac{12}{20} \quad \frac{6}{20} \quad \frac{8}{20} \quad \frac{x}{20} \quad \frac{y}{20}$$

La moyenne de l'élève est 7,5/15.

Sachant que $\frac{y}{3}$ vaut le double de $\frac{x}{10}$, que valent les notes x et y ?

- ☐ A. $x = \frac{8}{20}$ et $y = \frac{16}{20}$
- ☐ B. $x = \frac{7}{20}$ et $y = \frac{17}{20}$
- ☐ C. $x = \frac{13}{20}$ et $y = \frac{11}{20}$
- ☐ D. $x = \frac{10}{20}$ et $y = \frac{12}{20}$
- ☐ E. Aucune de ces quatre réponses

2 Après avoir corrigé un test de mathématiques, le professeur a réparti les notes (/20) obtenues par ses élèves en cinq classes, comme le présente le tableau suivant :

Ligne i	Classes	Valeur centrale x_i	Effectifs n_i	Fréquence f_i	Fréquence cumulée f_c
1	[0, 4[	2	4	0,10	?
2	[4, 8[	6	8	0,20	0,30
3	[8, 12[	10	10	0,25	0,55
4	[12, 16[	14	12	0,30	0,85
5	[16, 20[	18	6	0,15	?

Parmi les affirmations suivantes, indiquer celles qui sont correctes.

- ☐ A. À la cinquième ligne, $f_c = 100\%$.
- ☐ B. La fréquence cumulée de la première ligne vaut 0,10.
- ☐ C. Le caractère étudié est la note obtenue au test.
- ☐ D. Le nombre de copies corrigées par le professeur est égal à 40.

- ☐ E. Le mode est égal à 10.
- ☐ F. La moyenne est égale à 12/20.
- ☐ G. La médiane est comprise entre 8/20 et 10/20.
- ☐ H. Le premier quartile (Q_1) est la plus petite note de la série pour laquelle 25 % des notes lui sont inférieures ou égales. Il est égal à 6.
- ☐ I. L'écart type est supérieur à 5/20.


3 Soit la série statistique à caractère quantitatif suivante :

Note/10	Nombre d'élèves
2	15
5	10
8	5

Pour avoir une moyenne égale à 5,00/10, il faut :

- ☐ A. augmenter chaque valeur de deux points
- ☐ B. augmenter chaque valeur de 10 %
- ☐ C. augmenter chaque valeur de 20 %
- ☐ D. augmenter chaque valeur d'un point
- ☐ E. aucune de ces quatre réponses

4 Le graphe suivant représente les fréquences cumulées d'une série statistique à caractère quantitatif :



La médiane est située entre :

- ☐ A. les valeurs 60 et 80
- ☐ B. les valeurs 80 et 100
- ☐ C. les valeurs 100 et 120
- ☐ D. les valeurs 100 et 140

5 On considère la série statistique suivante :

Note/10	Nombre d'élèves
2	15
5	10
8	5

Le mode de cette série est :

- ☐ A. 2 ☐ B. 5
☐ C. 8 ☐ D. 10
☐ E. 15

6 On considère la série statistique suivante : 1, 4, 2, 16, 8, 10, 5, 20, 3

Que vaut la médiane ?

- ☐ A. 1 ☐ B. 4
☐ C. 2 ☐ D. 8
☐ E. 5

7 On considère la série des données suivantes : 1, 4, 2, 17, 7, 10, 5, 20, 3, 6.

Que vaut la médiane ?

- ☐ A. 1 ☐ B. 2
☐ C. 4 ☐ D. 5,5
☐ E. 6

8 On considère une croissance stable d'une souche de bactéries qui se multiplie de façon exponentielle, de sorte qu'après 2 minutes, le nombre double : une bactérie se divise en deux, les deux bactéries filles grandissent à leur tour et se divisent en quatre et ainsi de suite.

En plaçant une seule bactérie de cette souche dans un cylindre gradué à 10h00 de matin, on constate qu'une heure plus tard, à 11h00, le cylindre est rempli de moitié.

On suppose que peu importe le nombre de bactéries, le taux de croisement est régulier et le temps de doublement est constant, toujours égal à 2 minutes.

Cochez l'heure à laquelle le cylindre gradué sera supposément plein.

- ☐ A. 11h02 ☐ B. 11h30
☐ C. 12h00 ☐ D. 12h02
☐ E. Aucune de ces quatre réponses n'est correcte.

Statistiques descriptives

1 La bonne réponse est E.

Notons m la moyenne sur vingt des 6 points que l'élève a obtenus en mathématiques :

$$m = \frac{10 + 12 + 6 + 8 + x + y}{6} = \frac{36 + x + y}{6}$$

Exprimons la moyenne $m = 7,5/15$ sur vingt : $m = \frac{20 \times 7,5}{15} = 10$

D'où

$$m = \frac{36 + x + y}{6} = 10 \Leftrightarrow x + y = 24$$

Si $\frac{y}{3}$ vaut le double de $\frac{x}{10}$, alors $\frac{y}{3} = \frac{2x}{10} = \frac{x}{5}$, ce qui implique que $5y = 3x$

On détermine x et y en résolvant le système suivant :

$$\begin{cases} 5y = 3x \\ x + y = 24 \end{cases} \Leftrightarrow \begin{cases} 3x - 5y = 0 \quad (\text{I}) \\ x + y = 24 \quad (\text{II}) \end{cases}$$

On multiplie les deux membres de l'équation (II) par (-3) , et on additionne les deux équations membre à membre :

$$\begin{cases} 3x - 5y = 0 \quad (\text{I}) \\ -3x - 3y = -72 \quad (\text{II}) \end{cases} \Leftrightarrow \begin{cases} -8y = -72 \quad (\text{I}) + (\text{II}) \\ x + y = 24 \quad (\text{II}) \end{cases} \Leftrightarrow \begin{cases} y = 9 \\ x + y = 24 \quad (\text{II}) \end{cases}$$

On obtient $y = 9$ et $x = \frac{5y}{3} = \frac{45}{3} = 15$

2 Les bonnes affirmations sont A, B, C et D.

Le tableau complété est :

Ligne i	Classes	Valeur centrale x_i	Effectifs n_i	Fréquence f_i	Fré. cumulée f_c	$ m - x_i ^2 \times n_i$
1	$[0, 4[$	2	4	0,10	0,10	309,76
2	$[4, 8[$	6	8	0,20	0,30	184,32
3	$[8, 12[$	10	10	0,25	0,55	6,4
4	$[12, 16[$	14	12	0,30	0,85	122,88
5	$[16, 20[$	18	6	0,15	1,00	311,04
$N = 40$						934,4
$m = 10,80$						$V = 23,36$

A. Vrai. À la cinquième ligne, $f_c = 1 = 100\%$

$$\left(\sum_{i=1}^{i=5} f_i = 1 \right)$$

B. Vrai.

C. Vrai.

D. Vrai, car $N = \sum_{i=1}^{i=5} n_i = 40$

E. Faux. Le mode est la classe dont l'effectif est le plus grand, soit $x_i = 14$ (ou la classe en ligne 4).

F. Faux. La moyenne est égale à $10,8/20$:

$$\begin{aligned} m &= \frac{1}{N} \sum_{i=1}^{i=5} n_i x_i \\ &= \frac{4 \times 2 + 8 \times 6 + 10 \times 10 + 12 \times 14 + 6 \times 18}{40} \\ &= 10,8 \end{aligned}$$

G. Faux.

La médiane correspond à la moyenne générale qui partage la série statistique en deux effectifs égaux, soit $40/2 = 20$. On peut dire aussi, qu'elle correspond à l'effectif cumulé 20 :

Ligne i	Classes	Effectifs n_i	Effectifs cumulés n_c
1	[0, 4[	4	4
2	[4, 8[	8	12
3	[8, 12[	10	22
4	[12, 16[	12	34
5	[16, 20[	6	40
		$N = 40$	

Constatons donc que le 20^e élève se trouve dans la classe [8, 12[et y occupe le 8^e rang (20 - 12). Le calcul de la médiane décrit par la formule d'interpolation linéaire est :

$$\text{Médiane} - \text{borne inférieure de la classe } [a, b[= \frac{b - a}{\text{effectif de la classe } [a, b[} \times \text{rang du } \left(\frac{N}{2}\right)^e \text{ dans la classe } [a, b[$$

La classe $[a, b[$ est la classe où se trouve le $\left(\frac{N}{2}\right)^e$ effectif : [8, 12[.

On obtient :

$$\begin{aligned} \text{Médiane} - \text{la borne inférieure de la classe } [8, 12[&= \frac{12 - 8}{\text{rang du } \left(\frac{40}{2}\right)^e \text{ dans la classe } [8, 12[} \\ &\Leftrightarrow \frac{\text{Médiane} - 8}{20 - 12} = \frac{4}{10} \end{aligned}$$

$$\text{D'où : Médiane} = 8 \times \frac{4}{10} + 8 = 11,2.$$

On en déduit donc que 50 % d'élèves ont eu une note inférieure ou égale à 11,2 et 50 % ont obtenu une note supérieure ou égale à 11,2.

H. Faux.

Le premier quartile (Q_1) est la plus petite note de la série pour laquelle 25 % des données lui sont inférieures ou égales. Il est calculé de la même façon que la médiane :

Ligne i	Classes	Effectifs n_i	Effectifs cumulés n_c
1	[0, 4[	4	4
2	[4, 8[	8	12
3	[8, 12[	10	22
4	[12, 16[	12	34
5	[16, 20[	6	40
		$N = 40$	

$$Q_1 - \text{la borne inférieure de la classe } [4, 8[= \frac{8 - 4}{\text{rang du } \left(\frac{40}{4}\right)^e \text{ dans la classe } [4, 8[} = \frac{4}{8}$$

$$\frac{Q_1 - 4}{10 - 4} = \frac{4}{8} \Leftrightarrow Q_1 = 7$$

I. Faux.

D'après les résultats du tableau ci-dessus :

$$V = \frac{1}{N} \sum_{i=1}^{i=5} (m - x_i)^2 \times n_i = \frac{934}{40} = 23,35$$

On en déduit l'écart type : $\sigma = \sqrt{V} = 4,83$

On conclut que les notes des élèves s'écartent de part et d'autre de la moyenne ($m = 10,8$) de 4,83 points sur vingt.

3 La bonne réponse est D

A. Faux, car

$$m = \frac{4 \times 15 + 7 \times 10 + 10 \times 5}{30} = 6$$

B. Faux, car

$$m = \frac{2 \times 15 + 5 \times 10 + 8 \times 5}{30} \times 1,10 = 4,4$$

C. Faux, car

$$m = \frac{2 \times 15 + 5 \times 10 + 8 \times 5}{30} \times 1,20 = 4,8$$

D. Vrai, car $m = \frac{3 \times 15 + 6 \times 10 + 9 \times 5}{30} = 5$

4 La bonne réponse est B, car c'est la valeur qui correspond à $f_c = 50\%$.

5 La bonne réponse est A, car le mode correspond à la modalité de la variable ayant le nombre d'effectif le plus grand.

6 La bonne proposition est E.

On classe les valeurs par ordre croissant : 1, 2, 3, 4, 5, 8, 10, 16, 20.

Le nombre de valeurs est impair ($n = 9$), donc la médiane est la valeur qui se trouve à la $\frac{n+1}{2}$ ème place, soit 5.

7 La bonne proposition est D.

On classe les valeurs par ordre croissant : 1, 2, 3, 4, 5, 6, 7, 10, 17, 20

Comme le nombre de valeurs est pair ($n = 10$), la médiane est la moyenne arithmétique de la $\frac{n}{2}$ ème (5ème) et de la $\frac{n+2}{2}$ ème (6ème) valeur, soit $\frac{5+6}{2} = 5,5$.

8 Réponse A.

A. Vrai, étant donné que le nombre de bactéries double toutes les 2 minutes. À 11h00 le cylindre était rempli de moitié, 2 min plus tard il sera donc entièrement rempli. À 11h04, le volume total occupé par les bactéries équivaldra au volume de deux cylindres et ainsi de suite.